

Lecture 10 Data Preparation

جب ہم اپنے data کو اپنے مینٹرنگ ماڈل کے مطابق بناتے ہیں
اس عمل کو Data Preprocessing کہتے ہیں۔ اس میں ہم اپنے
data set کو data میں جانے سے پہلے سے صرف دیکھنا لیتے ہیں

Steps : Preprocessing :

1) Remove the outliers : ^{Huber's SSE} ^{error threshold define} ^{knowledge}
outlier کو ہٹا کر ماڈل سے دور کرنا اور اسے remove کرنا۔

2) Box Plot : ^{Min} ^{max}
Box Plot سے ہم اپنے data سے outlier کو remove کر سکتے ہیں۔
جو کہ value min یا max سے زیادہ ہے اسے remove کر دیتے۔

2) Missing Data :

(1) جہاں پر missing value ہوگا وہاں پر اسے remove کر دیں (Inf. loss)
(2) جہاں پر column میں missing value ہوگا اسے average سے replace کر دیں
(3) اپنے data کو دیکھ کر value سے زیادہ اگر کسی پر اس کو missing
کے جگہ پر مل کر دیں۔

3) Non - Numeric Value handling : (one hot Encoding)

(1) اس میں ہم one hot Encoding کرتے ہیں اس میں ہم کاف سے
Unique value کو final کرتے ہیں۔ اگر unique value کا سٹر ہوگا اسے matrix

بنانا ہے۔

Matrix	Inter	Undergr	grad
$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$			
Matrix	replace		
$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$			
Inter			
$\begin{bmatrix} 0 & 1 & 0 & 0 \end{bmatrix}$			

non-numeric value کو Vector کے جگہ پر تبدیل کرنا۔

one vector \rightarrow one \rightarrow belong \rightarrow metric

\Rightarrow One More Method:

اس میں ہم اپنے کو unique value

Red \rightarrow 1

Green \rightarrow 2

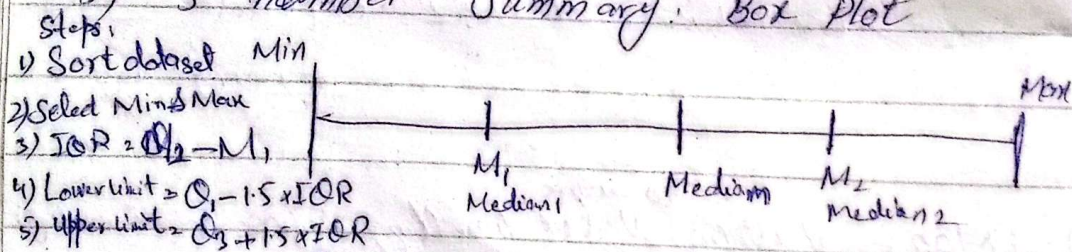
Yellow \rightarrow 3

again Red \rightarrow 1

اس میں ہم نے sequence learn کر لیا ہے

4) Feature Scaling: (اس کو scale کرنا ہے)

5) 5 number Summary: Box Plot



\Rightarrow Inter Quartal Range: IQR

اس میں ہم نے data کو scale کر لیا ہے

6) Noise Injection:

جس میں ہم نے data میں noise inject کر دیا ہے

اس میں ہم نے noise injection method

original data سے noise inject کر دیا ہے

⇒ Scaling:

data column/attribute (اس کی) range کے لئے اس میں سے select high value
 Instance کے لئے maximum
 Training time
 Exp: Training Iteration

Size (house)	Scaling Size
2000	$2000 / 6000 =$
4000	$4000 / 6000 =$
max ✓ 6000	$6000 / 6000 =$

$$\text{Formula: Scaling} = \frac{\text{Size}(x)}{\max(\text{Size})}$$

Feature Scaling Method:

1) Mean Normalization:

(1) اس میں سے mean calculate
 (2) ہر value سے mean منہ کرنا
 (3) ہر اس 'column' size divide maximum

$$\text{Normalization} = \frac{\text{value} - \text{mean}}{\max}$$

2) Min - Max Scaling:

$$x_{\text{new}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Scaled feature

Standard deviation scaling:

$$z = \frac{x - \mu}{\sigma}$$

$$\sigma = \sqrt{\frac{\sum (x - \mu)^2}{n}}$$

Box Plot & Five Number Summary

Dataset = {3, 10, 14, 19, 22, 29, 32, 36, 49, 70}

Step 1: Sort the dataset

Dataset Sorted = {3, 10, 14, 19, 22, 29, 32, 36, 49, 70}

Step 2: Five number Summary

- 1 - Minimum Value
- 2 - First Quartial Q_1 (25%)
- 3 - Median
- 4 - Third Quartial Q_3 (75%)
- 5 - Maximum

Step 3:

1) Upper Limit = $Q_3 + 1.5(IQR)$

$$= \overset{36}{36} + 1.5(\overset{22}{22}) = \boxed{69}$$

2) Lower Limit = $Q_1 - 1.5(IQR)$

$$= \overset{14}{14} - 1.5(22) = \boxed{-19}$$

Step 4: Calculate Q_1 , Q_3 , IQR

1) $Q_1 = \frac{25}{100} (\text{Total Instance} + 1)$

$$= \frac{25}{100} (10 + 1) = \frac{275}{100} = \boxed{2.75}$$

$Q_1 = 2.75 \rightarrow$ replace $\boxed{14}$

2) $Q_3 = \frac{75}{100} (\text{total instance} + 1)$

$$Q_3 = \frac{75}{100} (10 + 1) = \frac{825}{100} = 8.25$$

$Q_3 = 8.25 \rightarrow$ replace value $\boxed{36}$

3) $IQR = Q_3 - Q_1$

$$IQR = \cancel{8.25 - 2.75} = 36 - 14$$

$$\boxed{IQR = 22}$$

→ Draw box Plot:

Dataset = $\{3, 10, 14, 19, 22, 29, 32, 36, 49, 79\}$ } outlier

Five number Summary:

- 1) Minimum = 3
- 2) First Quartile $Q_1 = 14$
- 3) Median = 22
- 4) Third Quartile $Q_3 = 36$
- 5) Maximum = 49

Draw box Plot

